

Relatório de desenvolvimento do modelo de análise de sentimento para o CapInvest

by Capivara.Dev

O processo de desenvolvimento do fine-tuning para análise de sentimentos em notícias relacionadas ao mercado financeiro foi um trabalho minucioso e envolveu diferentes etapas. Inicialmente, o modelo FinBERT-BR foi utilizado. Para treinar o modelo, foram coletadas notícias do site Infomoney e esses dados foram anotados manualmente por várias pessoas, seguindo uma metodologia que consistia em avaliar a concordância entre as avaliações e realizar ajustes necessários.

Métricas do FinBERT-BR:

model Metrics				
	precision	recall	f1-score	support
0	0.56	0.50	0.53	20
1	0.55	0.79	0.65	14
2	0.68	0.61	0.64	41
accuracy			0.61	75
macro avg	0.59	0.63	0.60	75
weighted avg	0.62	0.61	0.61	75
Accuracy score	= 0.6133333333333333			
Precision score	= 0.6201841841841842			
Recall score	= 0.6133333333333333			

No entanto, os resultados obtidos com o modelo FinBERT-BR não foram satisfatórios, o que levou a uma mudança de abordagem e a adoção do modelo Multilingual-BERT. Esse modelo é pré-treinado com textos em diferentes idiomas, incluindo o português, o que o torna mais adequado para o problema em questão. Além disso, houve uma mudança na forma como as notícias foram processadas: em vez de utilizar o texto completo de cada notícia, elas foram divididas em frases e cada frase foi classificada em positiva, negativa ou neutra.

Os dados utilizados para treinamento foram obtidos a partir de um conjunto de dados disponibilizado pelos professores do projeto no Kaggle que é específico para análise de sentimento em notícias do mercado financeiro em português. O dataset em questão pode ser encontrado no seguinte link: <https://www.kaggle.com/datasets/mateuspicanco/financial-phrases-bank-portuguese-translation>. Posteriormente, utilizamos para testes dados tanto deste dataset quanto

do que coletamos do site infomoney. O modelo final treinado obteve uma acurácia de 82% no conjunto de teste do dataset obtido no Kaggle e 80% no dataset que coletamos, o que indica que ele é capaz de realizar uma boa análise de sentimentos em notícias relacionadas ao mercado financeiro em português.

Métricas do Multilingual-BERT:

model Metrics				
	precision	recall	f1-score	support
0	0.80	0.71	0.75	204
1	0.78	0.71	0.75	91
2	0.84	0.90	0.87	432
accuracy			0.82	727
macro avg	0.81	0.77	0.79	727
weighted avg	0.82	0.82	0.82	727
Accuracy score	= 0.8239339752407153			
Precision score	= 0.8221449418565345			
Recall score	= 0.8239339752407153			